

Diagnóstico Predictivo de Barras Rotas en Motores de Inducción mediante Integración de Modelos Térmicos y Máquinas de Soporte Vectorial

Kendall Chinchilla Navarro, 2022055783

Escuela de Ingeniería Electromecánica, Instituto Tecnológico de Costa Rica

Correo: kenchinchilla@estudiantec.cr

Curso: Máquinas Eléctricas

Profesor: Ing. Osvaldo Guerrero Castro

Semestre: I Semestre 2026

Resumen—Los motores trifásicos de inducción son ampliamente utilizados en aplicaciones industriales debido a su robustez y eficiencia; sin embargo, fallas asociadas al rotor, especialmente barras rotas, pueden provocar sobrecalentamiento, pérdidas de eficiencia y daños severos si no se detectan oportunamente. En este trabajo se presenta una integración entre modelos térmicos, mantenimiento predictivo e inteligencia artificial para el diagnóstico de fallas de barras rotas mediante Máquinas de Soporte Vectorial (SVM).

La metodología incluyó una revisión bibliográfica de investigaciones recientes relacionadas con monitoreo térmico, análisis de firma de corriente (MCSA) y aprendizaje supervisado aplicado a motores de inducción. Además, se desarrolló una implementación académica en Python utilizando Pandas, NumPy y Scikit-Learn para generar y analizar variables eléctricas, térmicas y mecánicas sintéticas representativas de condiciones normales, sobrecarga y barras rotas.

Los resultados mostraron una alta capacidad de clasificación mediante SVM para diferenciar estados operativos del motor. Asimismo, el modelo SVR permitió estimar la temperatura del rotor con adecuada correlación entre valores reales y predichos. Finalmente, se propuso una arquitectura conceptual orientada a futuras implementaciones industriales de monitoreo predictivo basadas en inteligencia artificial y adquisición de datos en tiempo real.

Index Terms—Motores de inducción, barras rotas, mantenimiento predictivo, modelos térmicos, máquinas de soporte vectorial, inteligencia artificial.

I. INTRODUCCIÓN

Los motores trifásicos de inducción representan uno de los sistemas electromecánicos más utilizados en aplicaciones industriales debido a su robustez, bajo costo de mantenimiento y elevada confiabilidad operativa. Diversos estudios indican que estos motores constituyen aproximadamente el 85 % al 90 % de las máquinas eléctricas utilizadas en procesos industriales, sistemas de bombeo, ventilación, transporte y manufactura [1], [2]. Debido a su importancia dentro de la industria moderna, cualquier degradación en su desempeño puede provocar pérdidas económicas considerables, reducción de eficiencia energética y paradas no programadas de producción.

A pesar de su robustez, los motores de inducción están expuestos continuamente a esfuerzos eléctricos, térmicos, mecánicos y ambientales que aceleran el deterioro de sus

componentes internos [3]. Entre las fallas más críticas se encuentran las asociadas al rotor, particularmente las fallas por barras rotas en rotores tipo jaula de ardilla. Este tipo de falla puede originarse por esfuerzos térmicos repetitivos, vibraciones mecánicas, ciclos frecuentes de arranque o defectos de fabricación [1]. Cuando una barra del rotor se fractura, la corriente se redistribuye hacia barras adyacentes, generando incrementos localizados de temperatura, desbalances electromagnéticos, oscilaciones de torque y aumento de vibraciones, lo que eventualmente puede conducir a una falla catastrófica del motor [2].

Tradicionalmente, el diagnóstico de fallas en motores de inducción se ha realizado mediante técnicas de monitoreo de condición basadas en análisis de vibración, inspección térmica y análisis de corriente del estator. Dentro de estas técnicas, el *Motor Current Signature Analysis* (MCSA) se ha consolidado como uno de los métodos no invasivos más utilizados para la detección de barras rotas, debido a que permite identificar componentes espectrales características asociadas al deslizamiento del motor [1]. Sin embargo, las metodologías tradicionales basadas únicamente en análisis espectral presentan limitaciones bajo condiciones de carga variable, presencia de ruido o fallas incipientes [3]. Estas limitaciones se vuelven especialmente relevantes en condiciones de baja carga o presencia de variaciones dinámicas de deslizamiento, donde las componentes espectrales asociadas a barras rotas pueden dificultar su identificación precisa.

En los últimos años, el mantenimiento predictivo basado en inteligencia artificial ha adquirido gran relevancia en el monitoreo de máquinas eléctricas. Técnicas de aprendizaje supervisado como redes neuronales, árboles de decisión y Máquinas de Soporte Vectorial (*Support Vector Machines*, SVM) han demostrado alta capacidad para identificar patrones complejos asociados a condiciones anormales de operación [4], [5]. Particularmente, SVM destaca por su capacidad de clasificación en espacios de alta dimensionalidad, buen desempeño con conjuntos de datos medianos y adecuada generalización ante problemas no lineales mediante el uso de funciones kernel [6]. Estas características convierten a SVM en una alternativa viable para aplicaciones de diagnóstico de fallas en motores de inducción.

Paralelamente, el desarrollo reciente de modelos térmicos avanzados ha permitido mejorar significativamente la estimación de temperatura en motores eléctricos. Métodos basados en gemelos digitales (*Digital Twin*), modelos de difusión térmica fraccional y técnicas de estimación mediante filtros de Kalman permiten estimar la temperatura del rotor y estator aun cuando no es posible medirla directamente [7]–[10]. La integración de variables térmicas con variables eléctricas y mecánicas representa una oportunidad importante para desarrollar esquemas de diagnóstico más robustos y cercanos al comportamiento físico real del motor.

No obstante, gran parte de los trabajos reportados en la literatura se enfocan únicamente en modelos térmicos, análisis de barras rotas o clasificación mediante inteligencia artificial de forma separada. Existen relativamente pocos enfoques que integren simultáneamente variables térmicas, eléctricas y mecánicas dentro de un esquema unificado de mantenimiento predictivo basado en aprendizaje supervisado.

En este contexto, el presente artículo propone una metodología académica para la detección de fallas de barras rotas en motores trifásicos de inducción mediante Máquinas de Soporte Vectorial. La propuesta integra variables eléctricas, térmicas y mecánicas dentro de un entorno computacional desarrollado en Python utilizando bibliotecas de análisis de datos y aprendizaje automático. El modelo considera condiciones de operación normal, sobrecarga y falla por barras rotas, evaluando el desempeño del clasificador mediante métricas como *accuracy*, *precision*, *recall*, F1-score y matriz de confusión. De esta manera, se busca demostrar la viabilidad de combinar modelado térmico y técnicas de inteligencia artificial para aplicaciones de mantenimiento predictivo en motores de inducción.

II. METODOLOGÍA

II-A. Fuentes de información utilizadas

La presente investigación se desarrolló mediante una revisión bibliográfica orientada al análisis de modelos térmicos, diagnóstico de fallas de barras rotas y técnicas de inteligencia artificial aplicadas a motores trifásicos de inducción. Para ello, se consultaron artículos científicos publicados principalmente entre los años 2021 y 2025 en bases de datos académicas reconocidas, incluyendo IEEE Xplore, Elsevier, Springer, MDPI y ScienceDirect.

La selección de referencias se enfocó en investigaciones relacionadas con mantenimiento predictivo, monitoreo de condición, modelado térmico de motores eléctricos, análisis de firmas de corriente (*Motor Current Signature Analysis*, MCSA) y algoritmos supervisados de clasificación, particularmente Máquinas de Soporte Vectorial (*Support Vector Machines*, SVM). Asimismo, se consideraron revisiones recientes del estado del arte con el objetivo de identificar tendencias actuales, limitaciones y oportunidades de investigación dentro del diagnóstico inteligente de fallas en motores de inducción.

Dentro de las principales referencias utilizadas destacan los trabajos de Luo et al. [7], Fu et al. [8], Jiang et al. [9] y Zhang et al. [10], enfocados en modelos térmicos avanzados basados en gemelos digitales, modelos de difusión térmica y técnicas de identificación de parámetros para estimación de temperatura en motores de inducción.

En el área de diagnóstico de fallas de barras rotas se utilizaron principalmente las investigaciones de Halder et al. [1], Chisedzi y Muteba [2], y Hamani et al. [3], las cuales abordan técnicas de análisis espectral, procesamiento de señales y monitoreo de condición mediante variables eléctricas y mecánicas.

Por otra parte, la implementación de técnicas de inteligencia artificial y aprendizaje supervisado se fundamentó en los estudios de Arabacı y Mohamed [6], Kim et al. [4], Maciejewski et al. [11] y Zachariades y Xavier [5], donde se analizan diferentes métodos de clasificación aplicados al diagnóstico de motores eléctricos, incluyendo Máquinas de Soporte Vectorial, redes neuronales y algoritmos de selección de características.

Adicionalmente, se emplearon textos de referencia clásica como *Máquinas Eléctricas* de Chapman [12] y el trabajo de Guerrero Castro [13], con el propósito de establecer las bases teóricas relacionadas con funcionamiento, pérdidas y fallas en motores trifásicos de inducción.

La metodología general del estudio consistió en integrar la información recopilada para desarrollar una propuesta académica de mantenimiento predictivo basada en variables eléctricas, térmicas y mecánicas, implementando posteriormente un modelo de clasificación mediante SVM en un entorno computacional desarrollado en Python.

II-B. Modelos térmicos estudiados

II-B1. Generación de calor en motores de inducción: El comportamiento térmico de los motores trifásicos de inducción constituye uno de los factores más importantes dentro del análisis de confiabilidad y mantenimiento predictivo de máquinas eléctricas. La temperatura influye directamente sobre la degradación del aislamiento, la eficiencia energética y la vida útil del motor, razón por la cual múltiples investigaciones recientes se han enfocado en desarrollar modelos capaces de estimar el comportamiento térmico del rotor y del estator bajo diferentes condiciones operativas [7]–[10].

En motores de inducción, las principales fuentes de generación de calor corresponden a las pérdidas por efecto Joule en los devanados, pérdidas magnéticas en el núcleo, pérdidas mecánicas por fricción y ventilación, así como pérdidas adicionales asociadas a armónicos y fenómenos electromagnéticos [12]. Estas pérdidas provocan incrementos de temperatura que pueden acelerarse bajo condiciones de sobrecarga, desbalance o presencia de fallas internas.

La acumulación excesiva de calor dentro del motor puede provocar degradación progresiva del aislamiento, reducción de eficiencia energética y disminución de la vida útil de los componentes electromecánicos. Debido a esto, el monitoreo térmico se ha convertido en un elemento fundamental dentro de las estrategias modernas de mantenimiento predictivo [3].

II-B2. Modelos térmicos tradicionales: Tradicionalmente, el análisis térmico de motores eléctricos se ha realizado mediante modelos térmicos concentrados (*Lumped Parameter Thermal Models*) y técnicas basadas en elementos finitos (FEM). Los modelos concentrados simplifican el sistema térmico utilizando redes equivalentes de resistencias y capacitancias térmicas, mientras que FEM permite estudiar la

distribución espacial de temperatura dentro del motor con mayor precisión [10].

Aunque los modelos FEM permiten obtener una representación térmica detallada del comportamiento interno del motor, su elevado costo computacional dificulta aplicaciones de monitoreo en tiempo real dentro de entornos industriales. En contraste, los modelos concentrados presentan menor complejidad computacional, aunque sacrifican precisión espacial en la estimación térmica.

II-B3. Técnicas modernas de estimación térmica: Con el avance de las técnicas de monitoreo inteligente, investigaciones recientes han incorporado metodologías basadas en gemelos digitales (*Digital Twin*), identificación de parámetros y filtros de estimación para mejorar la precisión térmica en tiempo real.

Luo et al. [7] desarrollaron una metodología basada en un gemelo digital orientado por datos para estimar la temperatura de motores de inducción considerando perturbaciones no lineales en parámetros eléctricos como resistencia e inductancia. El modelo emplea señales eléctricas medidas durante la operación para aproximar el comportamiento térmico del motor mediante ecuaciones diferenciales y modelos orientados por datos.

Por otra parte, Fu et al. [8] propusieron un modelo de difusión térmica fraccional combinado con un filtro de Kalman extendido para estimar la distribución axial de temperatura en conductores del estator. El estudio demostró que el uso de operadores fraccionales permite representar con mayor precisión los fenómenos de transferencia de calor bajo condiciones dinámicas de carga.

Adicionalmente, Jiang et al. [9] desarrollaron una red de identificación de parámetros con ramas diferenciadas paralelas para estimar la temperatura del rotor en motores refrigerados por aceite. Este enfoque integra técnicas de aprendizaje y estimación paramétrica para capturar variaciones térmicas complejas bajo diferentes condiciones operativas.

Más recientemente, Zhang et al. [10] implementaron un modelo predictivo basado en *Digital Twin* para monitoreo térmico del estator utilizando acoplamiento magnetotérmico y reducción de orden mediante descomposición ortogonal propia (*Proper Orthogonal Decomposition*, POD). Los resultados reportados mostraron errores inferiores al 5 % respecto a mediciones experimentales, reduciendo simultáneamente el tiempo computacional requerido por los modelos tradicionales FEM.

Los enfoques modernos basados en gemelos digitales y modelos orientados por datos presentan ventajas importantes en adaptabilidad y monitoreo continuo. Sin embargo, su desempeño depende significativamente de la calidad de los datos de entrenamiento y de la correcta calibración de parámetros físicos del motor.

En el contexto de la presente investigación, las variables térmicas son integradas junto con variables eléctricas y mecánicas dentro de un esquema de clasificación supervisada mediante Máquinas de Soporte Vectorial. Esta integración busca representar de manera más cercana el comportamiento físico real del motor bajo condiciones de operación normal, sobrecarga y falla por barras rotas.

II-C. Diagnóstico de fallas de barras rotas




Figura 1: Vista transversal mediante análisis por elementos finitos (FEM) de un motor de inducción bajo condiciones saludable, una barra rota (1 BRB) y tres barras rotas (3 BRB), adaptado de [14].

La Figura 1 muestra la distribución electromagnética obtenida mediante análisis por elementos finitos (FEM) para un rotor saludable y diferentes condiciones de barras rotas. Se observa que la concentración de flujo magnético alrededor de las barras dañadas aumenta significativamente, generando esfuerzos electromagnéticos y térmicos adicionales sobre las barras adyacentes [14].

Las fallas de barras rotas (*Broken Rotor Bars*, BRB) representan una de las fallas más frecuentes y críticas en motores de inducción tipo jaula de ardilla. Este tipo de falla puede originarse por esfuerzos térmicos repetitivos, ciclos frecuentes de arranque, vibraciones mecánicas, desbalances electromagnéticos o defectos de fabricación [1]. A medida que el rotor opera bajo condiciones severas, las barras conductoras experimentan esfuerzos térmicos y mecánicos que favorecen la aparición de grietas y fracturas parciales o totales.

Cuando ocurre una barra rota, la corriente inducida dentro del rotor se redistribuye hacia barras adyacentes, provocando incrementos localizados de temperatura y desbalances en el campo magnético giratorio. Estas alteraciones generan oscilaciones de torque, aumento de vibraciones mecánicas y variaciones en las corrientes del estator [2]. Además, las barras dañadas producen componentes espectrales características que pueden ser detectadas mediante análisis de corriente.

Dentro de las técnicas más utilizadas para diagnóstico de barras rotas destaca el análisis de firma de corriente del motor (*Motor Current Signature Analysis*, MCSA). Esta metodología permite identificar componentes laterales alrededor de la frecuencia fundamental asociadas al deslizamiento del motor [1]. Las frecuencias características de barras rotas pueden expresarse mediante:

$$f_{brb} = (1 \pm 2ks)f_s \quad (1)$$

donde f_s corresponde a la frecuencia de alimentación, s representa el deslizamiento del motor y k es un número entero positivo asociado a los armónicos laterales. Estas componentes espectrales suelen obtenerse mediante Transformada Rápida de Fourier (FFT) aplicada sobre las señales de corriente del estator.

Aunque MCSA constituye una técnica ampliamente utilizada debido a su carácter no invasivo y facilidad de implementación, diversos estudios reportan limitaciones importantes bajo condiciones de baja carga, presencia de ruido o fallas incipientes [3]. En estas condiciones, las componentes laterales pueden

presentar amplitudes reducidas, dificultando su identificación mediante métodos tradicionales basados únicamente en FFT.

Debido a estas limitaciones, investigaciones recientes han incorporado técnicas de inteligencia artificial y aprendizaje supervisado capaces de analizar simultáneamente variables eléctricas, térmicas y mecánicas [4], [11]. La integración de variables como temperatura, vibración, corriente y deslizamiento permite mejorar la capacidad de detección y clasificación de fallas complejas bajo diferentes condiciones operativas.

En el contexto de esta investigación, las variables asociadas al comportamiento térmico y electromecánico del motor son utilizadas como entradas de un modelo basado en Máquinas de Soporte Vectorial, buscando clasificar condiciones de operación normal, sobrecarga y presencia de barras rotas dentro de un entorno académico desarrollado en Python.

II-D. Métodos de análisis y comparación

La metodología propuesta en esta investigación se basa en la integración de variables eléctricas, térmicas y mecánicas dentro de un esquema de mantenimiento predictivo orientado al diagnóstico de fallas de barras rotas mediante Máquinas de Soporte Vectorial (*Support Vector Machines*, SVM). El objetivo principal consiste en clasificar diferentes condiciones operativas del motor utilizando información representativa del comportamiento físico y electromecánico del sistema.

II-D1. Variables utilizadas: Las variables de entrada seleccionadas fueron definidas considerando los principales indicadores asociados al comportamiento térmico y dinámico de motores trifásicos de inducción reportados en la literatura [4], [11]. Entre las variables consideradas se incluyen; corriente por fase del estator, temperatura del estator, temperatura del rotor, vibración mecánica, velocidad de rotación, deslizamiento del motor y carga mecánica aplicada.

Estas variables permiten representar condiciones asociadas a operación normal, sobrecarga y presencia de barras rotas, integrando simultáneamente efectos eléctricos, térmicos y mecánicos dentro del proceso de clasificación.

La variable de salida corresponde al estado operativo del motor, definido mediante tres categorías principales; operación normal, condición de sobrecarga y falla de barras rotas.

II-D2. Preprocesamiento y análisis de señales: Las señales eléctricas asociadas a corriente del estator pueden analizarse mediante Transformada Rápida de Fourier (FFT) para identificar componentes espectrales relacionadas con barras rotas. El uso de FFT permite extraer características frecuenciales asociadas al deslizamiento del motor y a las bandas laterales producidas por desbalances electromagnéticos [1].

Posteriormente, las variables obtenidas son organizadas dentro de un conjunto de datos estructurado utilizando herramientas de análisis numérico y procesamiento de datos en Python. Con el propósito de evitar dominancia entre variables de distinta magnitud física, se aplica un proceso de normalización previo al entrenamiento del modelo supervisado.

II-D3. Modelo de clasificación basado en SVM: El modelo de clasificación propuesto utiliza Máquinas de Soporte

Vectorial debido a su capacidad de separación de clases en espacios de alta dimensionalidad y su buen desempeño en problemas de clasificación no lineal [6]. A diferencia de métodos tradicionales basados únicamente en análisis espectral, SVM permite integrar múltiples variables simultáneamente, mejorando la capacidad de identificación de condiciones anormales bajo diferentes escenarios operativos.

El modelo busca encontrar un hiperplano óptimo que maximice la separación entre clases correspondientes a operación normal, sobrecarga y fallas de barras rotas. Para problemas no lineales, SVM puede emplear funciones kernel capaces de transformar los datos hacia espacios de mayor dimensionalidad, permitiendo mejorar la separabilidad entre condiciones del motor.

Aunque modelos basados en redes neuronales profundas pueden ofrecer alta precisión, suelen requerir grandes volúmenes de datos y mayor capacidad computacional. En contraste, SVM presenta ventajas importantes para aplicaciones académicas y conjuntos de datos medianos, manteniendo buena capacidad de generalización y menor complejidad de entrenamiento [4].

II-D4. Criterios de evaluación: Las métricas utilizadas para evaluar el desempeño del modelo fueron accuracy, precision, recall, F1-score y matriz de confusión.

Estas métricas permiten analizar la capacidad del modelo para identificar correctamente diferentes condiciones operativas del motor, evaluando tanto la precisión global como el comportamiento individual de cada clase.

Adicionalmente, se consideran comparaciones entre variables térmicas, eléctricas y mecánicas con el objetivo de analizar cuáles parámetros presentan mayor influencia dentro del proceso de clasificación de fallas.

Asimismo, se realizará una comparación entre variables eléctricas, térmicas y mecánicas con el propósito de analizar cuáles presentan mayor sensibilidad frente a condiciones de barras rotas. También se evaluará el desempeño del modelo SVM respecto a metodologías tradicionales basadas únicamente en análisis espectral mediante FFT y MCSA.

La comparación considera criterios asociados a capacidad de clasificación, robustez ante variaciones operativas y posibilidad de integración dentro de esquemas de mantenimiento predictivo. De esta manera, se busca analizar las ventajas y limitaciones del enfoque propuesto respecto a técnicas convencionales utilizadas en diagnóstico de motores de inducción.

La implementación completa del sistema de clasificación se desarrolla en Python utilizando bibliotecas especializadas como NumPy, Pandas, Scikit-Learn y Matplotlib, permitiendo realizar procesamiento de datos, entrenamiento supervisado y visualización de resultados dentro de un entorno académico orientado al mantenimiento predictivo de motores de inducción.

III. RESULTADOS Y DISCUSIÓN

III-A. Presentación de hallazgos relevantes

Con el propósito de validar la metodología propuesta, se desarrolló una implementación computacional en Python orientada al diagnóstico de fallas de barras rotas y estimación

térmica en motores trifásicos de inducción. El modelo fue evaluado utilizando un conjunto de datos sintético construido a partir de variables eléctricas, térmicas y mecánicas representativas del comportamiento operativo del motor bajo condiciones normales, sobrecarga y presencia de barras rotas.

El conjunto de datos incluyó variables asociadas a corriente por fase, temperatura del rotor y del estator, vibración mecánica, velocidad de rotación, carga mecánica y deslizamiento. Estas variables fueron utilizadas como entradas de un modelo supervisado basado en Máquinas de Soporte Vectorial (SVM) para clasificación de estados operativos y un modelo de Regresión por Máquinas de Soporte Vectorial (SVR) para estimación de temperatura del rotor.

Los resultados obtenidos dentro del entorno de simulación mostraron un desempeño satisfactorio del clasificador propuesto, alcanzando una exactitud (*accuracy*) de 98.67 %, así como valores de precisión, *recall* y *F1-score* cercanos al 99 %. Estos resultados evidencian una alta capacidad de separación entre condiciones normales, sobrecarga y fallas de barras rotas dentro del conjunto de datos analizado.




Figura 2: Matriz de confusión obtenida para el clasificador SVM propuesto.

La Figura 2 presenta la matriz de confusión correspondiente al clasificador SVM. Se observa que la mayoría de las muestras fueron clasificadas correctamente, especialmente en la condición de operación normal, donde no se registraron errores de clasificación. Asimismo, las principales confusiones ocurrieron entre las categorías de sobrecarga y barras rotas, comportamiento coherente con la similitud física existente entre ambas condiciones operativas, ya que ambas generan incrementos de temperatura, corriente y vibración dentro del motor.

Adicionalmente, se implementó un modelo de regresión SVR para estimar la temperatura del rotor a partir de variables eléctricas y mecánicas. El modelo obtuvo un error absoluto medio (MAE) de 4.48 °C, una raíz del error cuadrático medio (RMSE) de 5.54 °C y un coeficiente de determinación R^2 igual a 0.8678, indicando una correlación adecuada entre valores reales y predichos.




Figura 3: Comparación entre temperatura real y temperatura predicha mediante SVR.

La Figura 3 muestra la relación entre la temperatura real y la temperatura estimada por el modelo SVR. Se aprecia una tendencia aproximadamente lineal entre ambas variables, evidenciando que el modelo es capaz de capturar adecuadamente el comportamiento térmico general del motor. Sin embargo, también pueden observarse ciertas dispersiones para temperaturas elevadas, lo cual resulta esperable considerando la naturaleza no lineal de los fenómenos térmicos y electromagnéticos presentes en motores de inducción.

Con el objetivo de analizar la relación entre variables dinámicas del motor y las condiciones de falla, se evaluó adicionalmente el comportamiento conjunto entre vibración mecánica y deslizamiento.




Figura 4: Relación entre vibración mecánica y deslizamiento para diferentes condiciones operativas del motor.

La Figura 4 evidencia que las condiciones de barras rotas presentan mayores niveles de vibración y deslizamiento respecto a la operación normal. Asimismo, las condiciones de sobrecarga muestran un comportamiento intermedio entre ambas clases. Estos resultados coinciden con el comportamiento físico esperado en motores de inducción, donde las fallas de barras rotas generan desbalances electromagnéticos capaces de producir oscilaciones de torque, incremento de vibraciones y variaciones dinámicas en el deslizamiento del rotor.

Los resultados obtenidos dentro del entorno de simulación

demuestran que la integración simultánea de variables térmicas, eléctricas y mecánicas permite mejorar significativamente la capacidad de clasificación respecto a metodologías tradicionales basadas únicamente en análisis espectral mediante FFT y MCSA. Además, el uso de SVM permitió obtener fronteras de separación adecuadas incluso bajo presencia de superposición parcial entre ciertas condiciones operativas.

III-B. Comparación con estudios previos

Diversas investigaciones recientes han demostrado el potencial de las técnicas de inteligencia artificial para el diagnóstico de fallas en motores de inducción. En particular, las Máquinas de Soporte Vectorial han mostrado resultados favorables en problemas de clasificación relacionados con barras rotas, desbalances y fallas electromecánicas [2], [4], [6].

Arabacı y Mohamed [6] implementaron un sistema de detección de barras rotas utilizando SVM y análisis de corriente bajo condiciones de vacío. Los autores reportaron una adecuada capacidad de clasificación utilizando únicamente señales eléctricas provenientes del estator. Sin embargo, el enfoque se limitó principalmente a variables de corriente y análisis espectral mediante FFT.

Por otra parte, Kim et al. [4] compararon distintos modelos de inteligencia artificial, incluyendo SVM, redes neuronales y métodos de *boosting*, para diagnóstico de fallas en motores eléctricos. Los resultados mostraron que SVM presentó un desempeño competitivo especialmente en conjuntos de datos de tamaño moderado, manteniendo buena capacidad de generalización y menor complejidad computacional respecto a arquitecturas más profundas.

Asimismo, Chisedzi y Muteba [2] analizaron diferentes técnicas de aprendizaje automático aplicadas a detección de barras rotas utilizando variables de corriente y vibración. Los autores concluyeron que la integración de múltiples variables mejora significativamente la capacidad de clasificación respecto a metodologías tradicionales basadas únicamente en análisis de corriente.

Resultados similares fueron reportados por Maciejewski et al. [11], quienes realizaron una comparación entre técnicas de selección de características y métodos de clasificación utilizando señales de corriente y vibración. El estudio evidenció que las variables mecánicas y dinámicas presentan alta sensibilidad ante condiciones de barras rotas, especialmente bajo variaciones de carga.

En comparación con los trabajos previamente mencionados, la presente investigación propone una integración simultánea de variables eléctricas, térmicas y mecánicas dentro de un esquema de clasificación supervisada mediante SVM. A diferencia de enfoques centrados exclusivamente en FFT y MCSA, el modelo desarrollado considera además variables térmicas asociadas al comportamiento físico del motor, permitiendo representar de forma más completa los efectos provocados por condiciones de sobrecarga y barras rotas.

Adicionalmente, el uso combinado de clasificación SVM y regresión SVR permitió incorporar simultáneamente tareas de diagnóstico y estimación térmica dentro de una misma arquitectura computacional. Este enfoque busca aproximarse

a estrategias modernas de mantenimiento predictivo donde múltiples variables operativas son analizadas de manera conjunta para mejorar la detección temprana de fallas.

Tabla I: Comparación entre estudios recientes relacionados con diagnóstico de fallas en motores de inducción

Estudio	Variables	Método	Hallazgos principales
Arabacı y Mohamed (2021)	Corriente	SVM + FFT	Clasificación efectiva mediante análisis espectral.
Kim et al. (2023)	Corriente y vibración	SVM y Redes Neuronales	Buena generalización con datos medianos.
Chisedzi y Muteba (2023)	Corriente y vibración	Machine Learning	Mejora al integrar múltiples variables.
Maciejewski et al. (2025)	Corriente y vibración	Machine Learning + selección de características	Alta sensibilidad ante fallas BRB.
Trabajo propuesto	Variables térmicas, eléctricas y mecánicas	SVM + SVR	Diagnóstico y predicción térmica integrados.

La Tabla I resume las principales diferencias entre investigaciones recientes y el enfoque desarrollado en este trabajo. Se observa que la mayoría de estudios se enfocan principalmente en variables eléctricas y mecánicas, mientras que la presente investigación incorpora además variables térmicas dentro del proceso de clasificación y análisis predictivo.

III-C. Interpretación de resultados y limitaciones del estudio

Los resultados obtenidos evidencian que la integración simultánea de variables térmicas, eléctricas y mecánicas permite mejorar significativamente la capacidad de diagnóstico respecto a metodologías tradicionales basadas únicamente en análisis espectral. La combinación de variables como vibración, deslizamiento y temperatura del rotor permitió representar de forma más completa los efectos físicos asociados a condiciones de barras rotas dentro del motor de inducción.

La matriz de confusión mostró que la mayoría de condiciones operativas fueron clasificadas correctamente por el modelo SVM. Sin embargo, se observaron pequeñas confusiones entre las categorías de sobrecarga y barras rotas. Este comportamiento resulta físicamente coherente debido a que ambas condiciones generan incrementos similares de corriente, temperatura y deslizamiento, provocando superposición parcial entre ciertas regiones del espacio de características.

Asimismo, los resultados asociados a vibración y deslizamiento evidenciaron una clara tendencia de incremento bajo condiciones de barras rotas. Este comportamiento coincide con el fenómeno físico esperado en motores de inducción, donde las fallas del rotor generan desbalances electromagnéticos capaces de producir oscilaciones de torque y aumento de vibraciones mecánicas [1], [2].

Por otra parte, el modelo de regresión térmica basado en SVR presentó una adecuada correlación entre temperaturas reales y predichas. El coeficiente de determinación obtenido ($R^2 = 0,8678$) indica que el modelo fue capaz de capturar gran parte de la variabilidad térmica presente en el conjunto de datos analizado. No obstante, las dispersiones observadas para temperaturas elevadas sugieren que el comportamiento térmico

del motor presenta relaciones altamente no lineales difíciles de representar completamente mediante modelos simplificados.

En comparación con técnicas tradicionales basadas exclusivamente en FFT y MCSA, el enfoque propuesto presenta ventajas importantes al integrar múltiples variables simultáneamente dentro del proceso de clasificación. Mientras que las metodologías clásicas pueden verse afectadas bajo condiciones de baja carga o presencia de ruido, la incorporación de variables térmicas y mecánicas permite aumentar la robustez del diagnóstico frente a diferentes escenarios operativos.

A pesar de los resultados favorables obtenidos, la presente investigación presenta diversas limitaciones. En primer lugar, el conjunto de datos utilizado corresponde a una simulación académica basada en variables sintéticas representativas del comportamiento del motor. Aunque las relaciones físicas implementadas fueron diseñadas para aproximarse al comportamiento real de motores de inducción, no se utilizaron señales experimentales provenientes de bancos de prueba industriales.

Adicionalmente, el modelo desarrollado no considera fenómenos complejos presentes en entornos reales, tales como ruido electromagnético, variaciones bruscas de carga, desbalances de tensión, armónicos de red o degradación progresiva del aislamiento. Estos factores podrían afectar el desempeño del clasificador bajo condiciones industriales reales.


Otra limitación importante corresponde al tamaño del conjunto de datos utilizado para entrenamiento y validación. Aunque SVM presentó buena capacidad de generalización bajo el escenario estudiado, conjuntos de datos más extensos permitirían evaluar con mayor profundidad el comportamiento del modelo frente a fallas incipientes y condiciones operativas variables.

Como trabajo futuro, se recomienda incorporar adquisición de datos en tiempo real mediante sensores industriales, integración con plataformas IoT y validación experimental utilizando bancos de prueba de motores trifásicos de inducción. Asimismo, podrían evaluarse modelos más avanzados basados en aprendizaje profundo y técnicas híbridas de gemelos digitales orientadas al monitoreo térmico y mantenimiento predictivo inteligente.

III-D. Cómo se implementa en Python

La implementación computacional desarrollada en esta investigación corresponde a una prueba de concepto académica orientada al análisis predictivo de motores trifásicos de inducción mediante técnicas de inteligencia artificial. El sistema fue desarrollado en Python utilizando bibliotecas especializadas para procesamiento de datos, aprendizaje supervisado y visualización de resultados.

El flujo general del sistema propuesto se muestra en la Figura 5. Inicialmente, las variables eléctricas, térmicas y mecánicas del motor son organizadas dentro de un conjunto de datos estructurado. Posteriormente, las señales son preprocesadas mediante normalización y análisis de características antes de ser utilizadas por los modelos de clasificación y regresión.



Made with Napkin

Figura 5: Arquitectura general del sistema de diagnóstico y predicción térmica implementado en Python.

La arquitectura presentada evidencia la integración secuencial de variables eléctricas, térmicas y mecánicas dentro del proceso de mantenimiento predictivo. Asimismo, el diagrama permite observar cómo las etapas de preprocesamiento y normalización resultan fundamentales para el desempeño de los modelos SVM y SVR implementados.

La matriz de datos utilizada se construyó considerando variables representativas del comportamiento operativo del motor bajo condiciones normales, sobrecarga y presencia de barras rotas. La Tabla II resume las variables principales utilizadas durante el entrenamiento y validación del modelo.

Tabla II: Variables utilizadas dentro del conjunto de datos

Variable	Tipo	Descripción
Corriente por fase	Entrada	Corriente RMS del estator en cada fase.
Temperatura del estator	Entrada	Temperatura asociada a devanados y núcleo.
Temperatura del rotor	Entrada/Salida	Variable térmica utilizada para clasificación y regresión.
Vibración mecánica	Entrada	Vibración RMS asociada al comportamiento dinámico.
Velocidad	Entrada	Velocidad mecánica del rotor.
Deslizamiento	Entrada	Diferencia relativa entre velocidad síncrona y velocidad real.
Carga mecánica	Entrada	Nivel de carga aplicado al motor.
Estado del motor	Salida	Clasificación: Normal, Sobrecarga o Barras rotas.

Para el procesamiento de datos se utilizaron las bibliotecas

NumPy y Pandas, mientras que Scikit-Learn fue empleada para entrenamiento, validación y evaluación de los modelos supervisados. Adicionalmente, Matplotlib se utilizó para la generación de gráficas y visualización de resultados experimentales.

El modelo principal de clasificación fue implementado mediante Máquinas de Soporte Vectorial utilizando un kernel radial (*Radial Basis Function, RBF*). Este tipo de kernel permite representar relaciones no lineales entre variables térmicas, eléctricas y mecánicas presentes en el comportamiento dinámico del motor. La implementación fue desarrollada en Python utilizando la biblioteca *Scikit-Learn*, donde el kernel RBF es aplicado internamente por los modelos *SVC* y *SVR* utilizados durante el proceso de clasificación y regresión térmica.

La función básica de clasificación SVM puede representarse mediante:

$$f(x) = w^T x + b \quad (2)$$

donde w representa el vector de pesos, x corresponde al vector de características de entrada y b define el sesgo asociado al hiperplano de separación.

Sin embargo, debido a que las relaciones entre variables térmicas, eléctricas y mecánicas pueden presentar comportamientos no lineales, se utilizó un kernel radial (*Radial Basis Function, RBF*), el cual permite transformar implícitamente los datos hacia espacios de mayor dimensionalidad para mejorar la separación entre clases operativas del motor.

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (3)$$

donde γ representa el parámetro asociado al alcance de influencia de cada muestra dentro del espacio de características. El uso del kernel RBF permitió representar relaciones no lineales presentes entre variables térmicas, eléctricas y mecánicas bajo diferentes condiciones de operación del motor.

El conjunto de datos fue dividido utilizando una proporción de 75 % para entrenamiento y 25 % para validación. Posteriormente, las variables fueron normalizadas utilizando *StandardScaler* con el propósito de evitar dominancia entre parámetros de distinta magnitud física.

El clasificador SVM fue implementado utilizando un kernel RBF con un parámetro de regularización $C = 5$ y el parámetro γ configurado mediante la opción `scale` de *Scikit-Learn*. Asimismo, el modelo de regresión *SVR* fue implementado utilizando $C = 50$, $\epsilon = 2,0$ y kernel RBF. La configuración de estos parámetros permitió obtener una adecuada separación entre clases operativas y una estimación térmica estable dentro del entorno académico desarrollado.

Adicionalmente, se implementó un modelo de Regresión por Máquinas de Soporte Vectorial (SVR) orientado a estimar la temperatura del rotor a partir de variables eléctricas y mecánicas. Este modelo permitió generar comparaciones entre temperatura real y temperatura predicha, facilitando el análisis térmico dentro del esquema de mantenimiento predictivo.

La implementación desarrollada permitió generar automáticamente métricas de desempeño, matrices de confusión y gráficas comparativas para evaluar el comportamiento del

sistema bajo diferentes condiciones operativas. De esta manera, el entorno computacional construido permitió validar experimentalmente la capacidad de clasificación y predicción térmica del enfoque propuesto.

III-E. Implicaciones prácticas e industriales

Aunque la implementación desarrollada en esta investigación corresponde a una prueba de concepto académica, los resultados obtenidos evidencian el potencial de integración de técnicas de inteligencia artificial dentro de sistemas reales de mantenimiento predictivo para motores trifásicos de inducción.

El monitoreo continuo de condición (*Condition Monitoring*) en motores eléctricos ha adquirido gran relevancia dentro de entornos industriales modernos debido a su capacidad para detectar anomalías de forma temprana y reducir tiempos de inactividad no planificados [15]. En este contexto, la integración de variables eléctricas, térmicas y mecánicas permite construir sistemas de diagnóstico más robustos para aplicaciones de mantenimiento predictivo.

Bajo este enfoque, la arquitectura propuesta podría evolucionar hacia una plataforma de monitoreo en tiempo real capaz de adquirir continuamente variables como corriente RMS, vibración, temperatura y velocidad mediante sensores instalados directamente sobre el motor. La Figura 6 muestra una posible arquitectura conceptual para una futura implementación industrial del sistema desarrollado.




Figura 6: Propuesta conceptual de arquitectura industrial para monitoreo predictivo basado en SVM y modelos térmicos.

La adquisición de variables térmicas y mecánicas podría realizarse mediante sensores industriales especializados. Para la medición de temperatura podrían emplearse sensores RTD tipo PT100 o termopares industriales, mientras que la vibración mecánica podría monitorearse mediante acelerómetros piezo-eléctricos RMS. Asimismo, variables asociadas a velocidad y deslizamiento podrían obtenerse utilizando encoders ópticos o sensores basados en efecto Hall acoplados al eje del motor [15].

Las señales adquiridas podrían integrarse mediante módulos DAQ, PLCs industriales o sistemas SCADA orientados al monitoreo continuo de condición. Adicionalmente, protocolos de comunicación industrial como OPC-UA, Modbus TCP/IP o MQTT permitirían el intercambio de información entre sensores, servidores y plataformas de supervisión dentro de entornos industriales distribuidos [16].

Posteriormente, la información adquirida podría almacenarse para el análisis histórico y trazabilidad de condiciones operativas del motor. Dentro de esta arquitectura, un servidor de procesamiento basado en Python podría ejecutar continuamente los modelos SVM y SVR desarrollados en esta investigación. El clasificador SVM tendría la capacidad de identificar automáticamente condiciones normales, sobrecarga o presencia de barras rotas, mientras que el modelo SVR permitiría estimar tendencias térmicas asociadas al comportamiento del rotor.

A nivel operativo, una plataforma SCADA o interfaz HMI industrial permitiría visualizar variables eléctricas y térmicas en tiempo real, generar alarmas automáticas ante detección de fallas y almacenar tendencias históricas de temperatura y vibración para apoyar procesos de diagnóstico y mantenimiento predictivo.

La incorporación de este tipo de plataformas permitiría migrar desde esquemas tradicionales de mantenimiento correctivo hacia estrategias inteligentes de mantenimiento predictivo, reduciendo tiempos de inactividad, costos operativos y riesgo de fallas catastróficas en motores eléctricos utilizados en aplicaciones industriales críticas.

Finalmente, futuras extensiones del sistema podrían integrar adquisición de datos en tiempo real y modelos de aprendizaje continuo orientados a mejorar progresivamente la capacidad de diagnóstico bajo condiciones reales de operación.

IV. CONCLUSIONES Y RECOMENDACIONES

La presente investigación permitió analizar la integración de modelos térmicos y técnicas de inteligencia artificial para el diagnóstico de fallas de barras rotas en motores trifásicos de inducción. A partir de la revisión bibliográfica realizada, se identificó que las tendencias actuales de mantenimiento predictivo se orientan hacia la combinación de variables eléctricas, térmicas y mecánicas con algoritmos supervisados capaces de detectar condiciones anormales de operación de manera temprana.

Los resultados obtenidos evidenciaron que las Máquinas de Soporte Vectorial presentan una adecuada capacidad de clasificación para distinguir entre condiciones normales, sobrecarga y presencia de barras rotas. Asimismo, variables como vibración RMS, deslizamiento y temperatura del rotor demostraron alta sensibilidad frente a condiciones de falla, permitiendo mejorar la separación entre estados operativos respecto a metodologías tradicionales basadas únicamente en análisis espectral de corriente.

Adicionalmente, la incorporación del modelo de regresión SVR permitió estimar el comportamiento térmico del rotor con una correlación adecuada entre temperaturas reales y predichas. Esto demuestra el potencial de las técnicas de inteligencia artificial no solo para tareas de clasificación de fallas, sino también para monitoreo térmico y análisis predictivo de condiciones operativas dentro del motor.

Desde una perspectiva industrial, el enfoque desarrollado evidencia el potencial de integración de sistemas inteligentes de monitoreo dentro de estrategias modernas de mantenimiento predictivo. La incorporación de sensores, plataformas

de adquisición de datos y arquitecturas basadas en inteligencia artificial podría permitir la detección temprana de fallas, reducción de tiempos de inactividad y disminución de costos asociados a mantenimiento correctivo en aplicaciones industriales críticas.

No obstante, la presente investigación presenta limitaciones asociadas principalmente al uso de datos simulados y ausencia de validación experimental en bancos de prueba reales. Asimismo, no se consideraron fenómenos complejos presentes en entornos industriales como ruido electromagnético, variaciones dinámicas de carga o degradación progresiva de componentes internos del motor.

Como trabajo futuro, se recomienda desarrollar plataformas de adquisición de datos en tiempo real utilizando sensores industriales e integración con sistemas SCADA e IoT. De igual manera, futuras investigaciones podrían incorporar modelos híbridos basados en gemelos digitales, aprendizaje profundo y aprendizaje continuo para mejorar la robustez y adaptabilidad de los sistemas de diagnóstico predictivo aplicados a motores eléctricos industriales.

DISPONIBILIDAD DEL CÓDIGO

El código fuente desarrollado para la implementación académica del sistema de diagnóstico predictivo y predicción térmica se encuentra disponible públicamente en GitHub para fines educativos y de investigación:

Repositorio GitHub oficial del proyecto

REFERENCIAS

- [1] S. Halder, S. Bhat, D. Zychma, and P. Sowa, "Broken rotor bar fault diagnosis techniques based on motor current signature analysis for induction motor—a review," *Energies*, vol. 15, no. 22, p. 8569, 2022.
- [2] L. P. Chisedzi and M. Muteba, "Detection of broken rotor bars in cage induction motors using machine learning methods," *Sensors*, vol. 23, no. 22, p. 9079, 2023.
- [3] A. Hamani *et al.*, "Advancements in induction motor fault diagnosis and condition monitoring: A comprehensive review," *Sensors*, vol. 25, no. 19, p. 5942, 2025.
- [4] M.-C. Kim, J.-H. Lee, D.-H. Wang, and I.-S. Lee, "Induction motor fault diagnosis using support vector machine, neural networks, and boosting methods," *Sensors*, vol. 23, no. 5, p. 2585, 2023.
- [5] A. Zachariades and J. Xavier, "A review of artificial intelligence techniques in fault diagnosis of electric machines," *Sensors*, vol. 25, no. 16, p. 5128, 2025.
- [6] H. Arabacı and A. Mohamed, "Detection of induction motor broken rotor bar faults under no load condition by using support vector machines," *International Journal of Intelligent Engineering Informatics*, vol. 9, no. 5, pp. 470–486, 2021.
- [7] Y. Luo, L. Wang, D. Sidorov, A. Dreglea, and E. Chistyakova, "An approach to estimate the temperature of an induction motor under nonlinear parameter perturbations using a data-driven digital twin technique," *Energies*, vol. 17, no. 19, p. 4996, 2024.
- [8] W. Fu *et al.*, "Axial temperature distribution estimation of induction motor slot conductors using a fractional-order thermal diffusion model and extended kalman filter," *Applied Thermal Engineering*, vol. 277, p. 126831, 2025.
- [9] H. Jiang *et al.*, "Rotor temperature estimation for oil-cooled induction machines by a parameter identification network with parallel differentiated branches," *Mechanical Systems and Signal Processing*, vol. 224, p. 112245, 2025.
- [10] Y. Zhang *et al.*, "Digital twin-enabled predictive thermal modeling for stator temperature monitoring in induction motors," *Electronics*, vol. 14, no. 14, p. 2814, 2025.
- [11] M. Maciejewski *et al.*, "Comparative analysis of feature selection and classification techniques for robust broken rotor bar diagnosis in induction motors using current and vibration signals," *Autonomous Intelligent Systems*, vol. 5, no. 1, p. 26, 2025.

- [12] S. J. Chapman, *Máquinas Eléctricas*, 5th ed. McGraw-Hill, 2012.
- [13] O. Guerrero Castro, “Prevención de las fallas de los motores trifásicos de inducción mediante una adecuada selección,” *Tecnología en Marcha*, vol. 23, no. 1, pp. 78–93, 2010.
- [14] M. A. Khan, B. Asad, T. Vaimann, and A. Kallaste, “An advanced diagnostic approach for broken rotor bar detection and classification in dtc controlled induction motors by leveraging dynamic shap interaction feature selection (dshap-ifs) gbdt methodology,” *Machines*, vol. 12, no. 7, p. 495, 2024.
- [15] X. L. Y. Liu and H. Zhang, “Condition monitoring techniques for induction motors: A review,” *Sensors*, vol. 23, no. 5, p. 2458, 2023.
- [16] T. S. F. Dobaj and S. Soucek, “Opc ua and mqtt in industrial applications,” *IEEE Industrial Electronics Magazine*, vol. 15, no. 3, pp. 54–63, 2021.